

Тема: Обучение нейронной сети PointNet++ для семантической сегментации облака точек.

Цель работы:

1. Освоить принципы работы архитектуры PointNet++.
2. Приобрести практические навыки подготовки данных 3D-объектов для семантической сегментации.
3. Проанализировать качество предсказаний модели.

Теоретическое введение

Семантическая сегментация облака точек — задача присвоения каждой точке 3D-облака метки класса (например, "стена", "пол", "стол", "кресло"). Это ключевая проблема в робототехнике, автономном вождении и дополненной реальности.

PointNet++ — развитие архитектуры PointNet, которая напрямую обрабатывает неупорядоченные наборы точек. Ключевые усовершенствования:

1. **Иерархическая структура:** Сеть организует точки в вложенные группы, создавая локальные области с разной степенью детализации (sampling & grouping).
2. **Извлечение локальных признаков:** Внутри каждой локальной области применяется мини-сеть, подобная PointNet, для извлечения признаков, учитывающих локальную геометрию.
3. **Интерполяция признаков (Upsampling):** Для задачи сегментации признаки после самых глубоких слоев интерполируются обратно на исходные точки, комбинируя локальную и глобальную информацию.

Архитектура позволяет модели эффективно учитывать не только глобальную структуру объекта, но и локальные особенности, что критически важно для точной сегментации.

Оборудование и программное обеспечение

1. **Аппаратное обеспечение:** Компьютер с GPU (желательно NVIDIA с поддержкой CUDA).
2. **Программное обеспечение:**
 - ОС: Linux или Windows.
 - Язык программирования: Python 3.8+.
 - Фреймворк: PyTorch.

- Библиотеки: `torch`, `torch.nn`, `numpy`, `open3d` или `trimesh` для визуализации, `scikit-learn` для метрик, `tqdm`.

3. Датасет:

- Stanford 3D Indoor Spaces (S3DIS) . Датасет содержит сканы зданий с разметкой 13 классов (потолок, пол, стена, балка, колонна, окно, дверь, стол, стул, диван, книжная полка, доска, clutter). Ссылка на скачивание предоставляется преподавателем или на официальном ресурсе разработчика.
 - Дополнительный датасет предоставляемый преподавателем.
-

Порядок выполнения работы

Часть 1: Подготовка среды и данных

1. Установите необходимые библиотеки
2. Загрузите и подготовьте датасет S3DIS (Area_1) или датасет предоставленный преподавателем. Данные должны быть преобразованы в массив точек $(N, 6)$, где N — количество точек, а 6 каналов — это (x, y, z, r, g, b) и, опционально, нормали (минимальный случай (x,y,z)).
3. Реализуйте свой класс Dataset (самостоятельно разделите обучающую, валидационную и тестовые выборки).

Часть 2: Архитектура модели и обучение

1. Реализуйте или используйте готовую реализацию PointNet++ для сегментации
2. Определите функцию потерь. Для задачи семантической сегментации с несколькими классами используйте **Cross-Entropy Loss**. Учтите возможный дисбаланс классов в данных (можно использовать веса классов).
3. Настройте процесс обучения:
 - Оптимизатор: `Adam` с начальным `learning rate = 0.001`.
 - Планировщик (scheduler): `StepLR` для уменьшения `learning rate` каждые 20 эпох.
 - Количество эпох: 50-100 (можно увеличить).
 - Размер батча: Максимально возможный для вашего GPU (начните с 8-16) или CPU.
4. **Задание:** Запустите обучение модели. В процессе обучения записывайте значения функции потерь на тренировочной и валидационной выборках для построения графиков (по возможности и наличию навыков работы использовать TensorBoard).

Часть 3: Валидация и тестирование

1. Реализуйте функцию для расчета метрик качества сегментации на валидационном наборе:
 - **Overall Accuracy (OA):** Доля правильно классифицированных точек от общего числа.
 - **Mean Intersection over Union (mIoU):** Для каждого класса вычисляется $\text{IoU} = \text{TP} / (\text{TP} + \text{FP} + \text{FN})$, затем берется среднее значение по всем классам.
2. **Задание:** После завершения обучения:
 - Постройте графики обучения (train/val loss).
 - Рассчитайте OA и mIoU на тестовом наборе данных .
 - Визуализируйте результаты сегментации для нескольких тестовых блоков. Используйте `open3d` для отображения исходного облака (цвет RGB) и предсказанных классов (цветовая палитра по классам) или любую другую библиотеку или модуль для визуализации.

Часть 4: Анализ результатов

1. Проанализируйте график обучения. Присутствуют ли признаки переобучения (сильное расхождение train и val loss)? Как изменялась точность с ростом эпох?
2. Проанализируйте таблицу IoU по классам.
 - Какие классы сегментируются лучше всего (например, "пол", "потолок")? Почему?
 - Какие классы имеют низкий IoU (например, "доска", "диван")? В чем возможные причины (недостаток данных, схожесть геометрии с другими объектами, малый размер)?
3. **Задание:** Предложите и попробуйте реализовать способ улучшения качества модели.

Контрольные вопросы

1. В чем основное ограничение оригинального PointNet, которое преодолевает PointNet++?
2. Каковы основные проблемы при работе с реальными данными 3D-сканирования (на примере S3DIS), влияющие на качество сегментации?
3. Почему метрика mIoU является более информативной по сравнению с Overall Accuracy для задачи семантической сегментации?

Требования к отчету

Отчет должен содержать:

1. Титульный лист.

2. Цель работы.
 3. Краткое теоретическое введение (схема архитектуры PointNet++).
 4. Описание экспериментальной установки (версии ПО, параметры GPU).
 5. **Результаты выполнения:**
 - Графики хода обучения (loss).
 - Таблицы с рассчитанными метриками OA и mIoU на тестовой выборке.
 - Скриншоты визуализации исходных облаков и результатов сегментации (минимум 3 примера).
 - Анализ качества по классам (какие сегментируются хорошо/плохо и почему).
 6. Ответы на контрольные вопросы.
 7. Выводы по работе, где указать: достигнута ли цель, с какими трудностями столкнулись, какие есть пути улучшения модели.
-

Справочные материалы

1. <https://arxiv.org/pdf/1706.02413>
2. Репозиторий с официальной реализацией: [charlesq34/pointnet2](https://github.com/charlesq34/pointnet2)
3. Пример: PyTorch реализация PointNet++ для сегментации:
[yanx27/Pointnet_Pointnet2_pytorch](https://github.com/yanx27/Pointnet_Pointnet2_pytorch)